

## 0 摘要

真实网络数据的机器阅读理解 (MRC) 往往需要机器通过分析搜索引擎检索到的多个文章来回答问题。与单文章 MRC 相比, 多文章 MRC 更具有挑战性, 因为可能从不同文章得到多个混淆候选答案。为了解决者问题, 本文提出端到端的神经网络, 使得不同文章得到的候选答案可以基于它们代表的内容互相验证。具体地讲, 我们的模型联合训练三个模块, 即基于三个因素预测答案: 答案的边界、答案内容及多文章间答案验证。实验结果显示, 我们的方法在英语 MS-MARCO 数据库及中文 DuReader 数据库上效果远优于基准线并取得很好的成绩, 两者都是实际语境中为 MRC 设计的数据库。

## 1 介绍

机器阅读理解 (MRC) 使计算机可以从文本数据中获取数据并回答问题, 这被看作构建普遍智能引擎的关键步骤。近几年 MRC 社区发展迅猛。随着多数据库的发布, MRC 任务已经从早期填空进阶到从单文章中抽取答案, 再到最近从网络数据中回答更复杂的问题。

研究者为 MRC 任务付出巨大的努力开发模型, 尤其是单文章的答案抽取。这是一个里程碑, 几个 MRC 方法在 SQuAD 数据库效果已超过人工。然而, 仅仅是在维基百科文章中的成功是不够的, 终极目标是理解整个网络。因此, 几个新数据库, 在包含搜索引擎更真实语境下设计 MRC 任务。

多文章 MRC 内在挑战是所有文章是问题相关的又往往是独立写作的, 可能存在多个混淆候选答案。表 1 展示了 MS-MARCO 中的一个例子。可以看出, 所有答案都是与问题语义匹配的, 但字面上又很不相同甚至是错误的。Jia and Liang (2017) 指出, 对 MRC 模型来说, 区分混淆候选答案是非常困难的。因此, 针对多文章 MRC 问题需要特别的考虑。

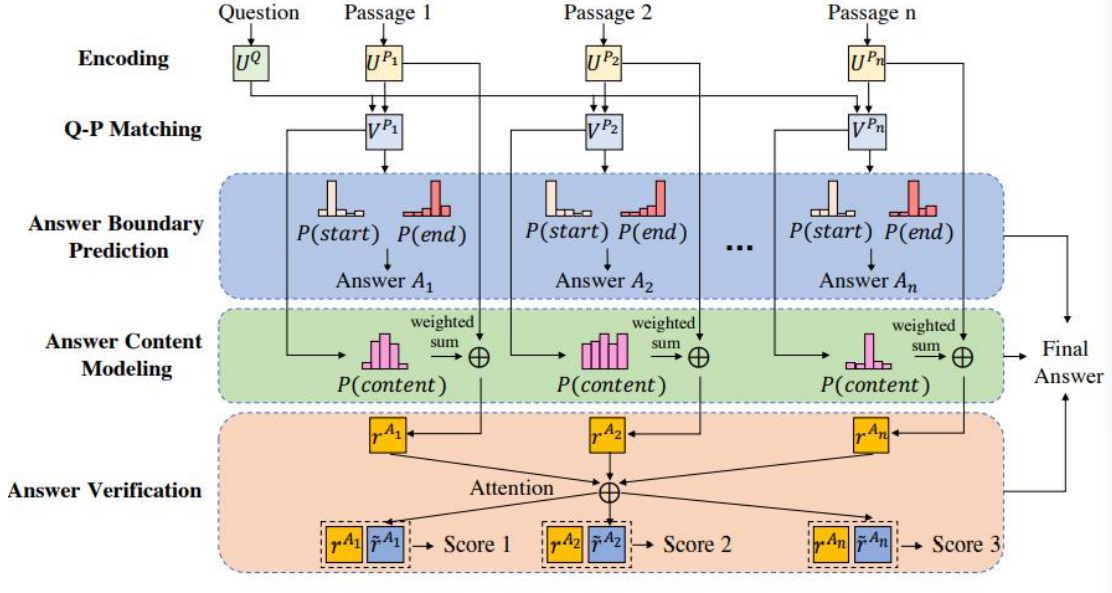
本文中, 我们提出从不同文章中验证最终正确答案, 剔除不正确答案。我们的假设是正确答案出现更频繁并具有一些共性, 错误答案各不相同。表 1 中的例子阐明了这种现象。从最后四段中抽取的答案都是正确答案, 互相语义相关, 另外两段中答案错误且不能从其他段落中得到支持信息。就像人工往往比较不同来源中的候选答案推导出最终答案, 希望 MRC 模型可以在跨文章答案验证过程中优化。

本文模型总体框架如图 1, 包含三个模块。首先是答案边界模型 (Seo et al., 2016), 识别答案的开头及结尾位置找到每篇文章的候选答案 (图 2)。第二, 建模文章中抽取的候选答案意义, 利用内容得分从另一角度衡量候选答案的质量。第三, 根据候选答案代表的含义互相印证。希望候选答案可以根据语义相关性互相提供支持, 最终判断答案是否正确。因此, 最终答案被三种因素决定: 边界、内容及跨文章答案验证。这三步骤分别是不同的模型, 在我们端到端框架中联合训练。我们在 MS-MARCO 和 DuReader 数据库上做实验。实验显示, 效果远优于基准线并取得很好的成绩。

## 2 方法

图 1 展示了多文章 MRC 模型的全貌, 由三部分组成: 预测边界、答案建模

及答案验证。首先，我们构建问题与文章。参考 Seo(2016)，我们对每篇文字计算 question-aware 表示。基于表示，我们利用 Pointer 网络 (Vinyals2015) 预测答案边界。同时，通过答案内容模型，我们评估每个单词是否应在答案中，获得答案表示。接下来，在答案验证模型中，候选答案寻找互相支持信息，计算得分显示答案是否正确。最终结果由答案边界、内容及验证得分共同决定。



## 2.1 问题与文章模型

给定问题  $Q$  和搜索引擎检索到的文章  $\{P_i\}$ ，任务是找到问题的最优简明答案。首先，我们正式给出建模问题与文章的细节。

**编码器** 我们首先综合词嵌入及字符嵌入将每个单词映射到向量空间。然后，利用双向 LSTM 编码问题与文章。

$$\begin{aligned} \mathbf{u}_t^Q &= \text{BiLSTM}_Q(\mathbf{u}_{t-1}^Q, [\mathbf{e}_t^Q, \mathbf{c}_t^Q]) \\ \mathbf{u}_t^{P_i} &= \text{BiLSTM}_P(\mathbf{u}_{t-1}^{P_i}, [\mathbf{e}_t^{P_i}, \mathbf{c}_t^{P_i}]) \end{aligned}$$

其中， $\mathbf{e}_t^Q$  和  $\mathbf{c}_t^Q$  分别是  $t$  个词单词级别及字符级别的嵌入。 $\mathbf{u}_t^Q$  是问题中第  $t$  个词的编码向量。与之前的论文简单组成文章不同，我们在编码及匹配步骤独立处理文章。

**Q-P 匹配** MRC 的一个核心步骤是匹配问题与文章，使重要信息被高亮。我们利用注意力流层从两个方面实现 Q-P 匹配。问题与文章的相似矩阵转化成一个简单版本，问题的第  $t$  个单词与文章的第  $k$  个单词的相似性计算如下：

$$\mathbf{S}_{t,k} = \mathbf{u}_t^{Q\top} \cdot \mathbf{u}_k^{P_i}$$

然后，内容-问题注意力和问题-内容注意力严格依照 Seo(2016)，获得文章表示  $\{u_i^p\}$ 。鉴于空间有限，我们不给出细节。另外，利用另一个双向 LSTM 模型融合上下文信息，获得文章中每一个单词的新表示，作为匹配输出：

$$v_t^{P_i} = \text{BiLSTM}_M(v_{t-1}^{P_i}, \tilde{u}_t^{P_i})$$

得到文章表示，引入本文模型的三个部分。

## 2.2 预测答案边界

从文章中抽取答案，主流研究试图定位答案边界，被称作边界模型。根据 WANG2016 我们采用 Pointer 网络 (Vinyals2015) 计算每个单词是答案开始或结尾的概率。

$$\begin{aligned} g_k^t &= \mathbf{w}_1^{a\top} \tanh(\mathbf{W}_2^a [\mathbf{v}_k^P, \mathbf{h}_{t-1}^a]) \\ \alpha_k^t &= \exp(g_k^t) / \sum_{j=1}^{|P|} \exp(g_j^t) \\ \mathbf{c}_t &= \sum_{k=1}^{|P|} \alpha_k^t \mathbf{v}_k^P \\ \mathbf{h}_t^a &= \text{LSTM}(\mathbf{h}_{t-1}^a, \mathbf{c}_t) \end{aligned}$$

利用注意力权重，文章中第  $k$  个单词是答案开头或结尾的概率分别是  $\alpha_k^1$  和  $\alpha_k^2$ 。注意 Pointer 网络应用于所有文章，所以文章间的概率是可以比较的。边界模型可以最小化真实开始及结尾指标的负对数概率得到：

$$\mathcal{L}_{\text{boundary}} = -\frac{1}{N} \sum_{i=1}^N (\log \alpha_{y_i^1}^1 + \log \alpha_{y_i^2}^2)$$

其中， $N$  是数据库样本数， $y_i$  是真实的开始及结尾位置。

## 2.3 回答内容建模

之前研究利用边界模型找到最大化边界得分的答案范围作为最终答案。然而，我们文章中，除了定位候选答案，还建模他们的意思以备后面验证。一个直觉的方法是抽取完答案再计算候选答案的表示，但非常难训练。这里，我们提出一个新颖的方法，基于概率获得候选答案的表示。

具体来说，我们改变传统 MRC 模型的输出层。除了预测文章中单词的边界概率，我们预测每个词是否应包含在答案里。第  $k$  个单词的内容概率是：

$$p_k^c = \text{sigmoid}(\mathbf{w}_1^c \top \text{ReLU}(\mathbf{W}_2^c \mathbf{v}_k^{P_i}))$$

训练内容模型非常直观。我们转换边界标签为连续分割，即单词在答案里标签为 1 否则为 0。因此，定义平均交叉熵为损失函数：

$$\mathcal{L}_{content} = -\frac{1}{N} \frac{1}{|P|} \sum_{i=1}^N \sum_{j=1}^{|P|} [y_k^c \log p_k^c + (1 - y_k^c) \log(1 - p_k^c)]$$

内容概率在边界之外提供另一个视角衡量答案的质量。而且，以此概率，我们将文章  $i$  提取出的答案作为文章中所有词嵌入的加权和。

$$\mathbf{r}^{A_i} = \frac{1}{|\mathbf{P}_i|} \sum_{k=1}^{|\mathbf{P}_i|} p_k^c [\mathbf{e}_k^{P_i}, \mathbf{c}_k^{P_i}]$$

#### 2.4 多文章答案验证

边界模型及内容模型致力于单文章中抽取及建模答案，很少考虑跨文章信息。然而，像第一部分阐释的，从不同文章中得到多个候选答案，有的会误导 MRC 模型得到错误预测。从不同文章汇总信息挑出最优候选是必要的。因此，我们提出新的方法，候选答案互相验证。

给定候选答案  $\{\mathbf{r}^{A_i}\}$ ，每一个候选答案依据注意力机制得到支持信息：

$$s_{i,j} = \begin{cases} 0, & \text{if } i = j, \\ \mathbf{r}^{A_i \top} \cdot \mathbf{r}^{A_j}, & \text{otherwise} \end{cases}$$

$$\alpha_{i,j} = \exp(s_{i,j}) / \sum_{k=1}^n \exp(s_{i,k})$$

$$\tilde{\mathbf{r}}^{A_i} = \sum_{j=1}^n \alpha_{i,j} \mathbf{r}^{A_j}$$

其中  $\mathbf{r}$  是从其他文章得到的注意力加权的验证信息，与原始答案代表  $\mathbf{r}$  得到全连接层。

$$g_i^v = \mathbf{w}^{v \top} [\mathbf{r}^{A_i}, \tilde{\mathbf{r}}^{A_i}, \mathbf{r}^{A_i} \odot \tilde{\mathbf{r}}^{A_i}]$$

不同文章得分归一化得到  $\mathbf{A}$  验证得分。

$$p_i^v = \exp(g_i^v) / \sum_{j=1}^n \exp(g_j^v)$$

为了训练验证模型，我们定义正确文章中的答案为正确答案。损失函数是正确答案的负对数概率。

$$\mathcal{L}_{verify} = -\frac{1}{N} \sum_{i=1}^N \log p_{y_i^v}^v$$

其中， $y$  是正确答案的指标。

## 2.5 联合训练与预测

像上面讨论的，我们在多文章 MRC 模型定义三个目标：找到答案边界，预测单词是不是在答案里，交叉文章验证找到最佳答案。像我们设计的，三个任务共享词向量、编码器和匹配层。因此，我们采用多任务训练，联合目标函数如下。

$$\mathcal{L} = \mathcal{L}_{boundary} + \beta_1 \mathcal{L}_{content} + \beta_2 \mathcal{L}_{verify}$$

我们先抽取每篇文章中边界得分最高的答案，边界得分是答案开始及结尾概率的乘积。对每个候选答案，平均所有词在答案中的得分。利用验证模型得到答案的验证分。因此，挑选最终答案基于以上三个分数。

## 3 实验

### 3.2 实验细节

对于 MS-MARCO，我们用可逆的斯坦福 CoreNLP 分词预处理词典，挑选获得最高 Rouge-L 得分的范围。使用 300 维预训练 Glove 词嵌入训练，字符嵌入是随机初始化为 30 维。对 DuReader，预处理在 he (2017) 中有写。

隐含层 150 个神经元，应用 L2 正则化， $\beta$  设为 0.5.采用 Adam 模型训练，初始学

习率 0.0004，批量大小为 32.训练变量采用指数移动平均，衰减率 0.9999.

训练结果：

Model	ROUGE-L	BLEU-1
FastQA_Ext (Weissenborn et al., 2017)	33.67	33.93
Prediction (Wang and Jiang, 2016)	37.33	40.72
ReasonNet (Shen et al., 2017)	38.81	39.86
R-Net (Wang et al., 2017c)	42.89	42.22
S-Net (Tan et al., 2017)	45.23	43.78
Our Model	<b>46.15</b>	<b>44.47</b>
S-Net (Ensemble)	46.65	44.78
Our Model (Ensemble)	<b>46.66</b>	<b>45.41</b>
Human	47	46

Performance of our method and competing models on the MS-MARCO



Model	BLEU-4	ROUGE-L
Match-LSTM	31.8	39.0
BiDAF	31.9	39.2
PR + BiDAF	37.55	41.81
Our Model	<b>40.97</b>	<b>44.18</b>
Human	56.1	57.4

Table 4: Performance on the DuReader test set

在 DuReader 数据库，我们利用 paragraph ranking 挑选代表段落训练，效果显著提升。

参考：

Min Joon Seo, Aniruddha Kembhavi, Ali Farhadi, and Hannaneh Hajishirzi. 2016. Bidirectional attention flow for machine comprehension. *arXiv preprint arXiv:1611.01603*.

Oriol Vinyals, Meire Fortunato, and Navdeep Jaitly. 2015. Pointer networks. In *Advances in Neural Information Processing Systems 28: Annual Conference on Neural Information Processing Systems 2015, December 7-12, 2015, Montreal, Quebec, Canada*. pages 2692–2700.